Resolución de ejercicios seleccionados del parcial de estadística 18/07/2020

Problema 1

Enunciado

Interesa estudiar la vida útil de ciertas baterías de automóvil. Para ello se dispone de una muestra aleatoria simple de duraciones de diez baterías cuyos datos, en meses, son:

22.0, 23.5, 31.0, 6.0, 18.6, 44.3, 19.5, 26.3, 23.9, 29.5

Se sabe que la distribución de las duraciones es exponencial con parámetro λ. Dicho parámetro es estimado, por máxima verosimilitud, mediante $\hat{\lambda}^{MV} = \frac{1}{\bar{X}}$ donde $\bar{X}$ es la media muestral. El gobierno tiene mil baterías del tipo estudiado que han sido todas instaladas en vehículos hace 5 meses, habiendo, al día de la fecha funcionado correctamente todas ellas. ¿Cuál es su estimación del número de baterías que se agotarán en los próximos 7 meses?

Resolución

$X_i :=$ "Duración en meses de la i-ésima batería" $i = 1, \dots, 10$

$X_i \sim E(\lambda)$. La función de distribución acumulada de X será:

$$F(X) = P(X \leq x) = \begin{cases} 1 - e^{-\lambda x}, x \geq 0 \\ 0 \qquad\qquad , c.c \end{cases}$$

Buscamos estimar la siguiente probabilidad condicional:

$$P(X \leq 12 | X \geq 5) = \frac{P(X \leq 12 \wedge X \geq 5)}{P(X \geq 5)} = \frac{P(5 \leq X \leq 12)}{P(X \geq 5)} = \frac{\left[1 - e^{-12\lambda}\right] - \left[1 - e^{-5\lambda}\right]}{1 - \left[1 - e^{-5\lambda}\right]} =$$

$$= \frac{e^{-5\lambda} - e^{-12\lambda}}{e^{-5\lambda}} = 1 - \frac{e^{-12\lambda}}{e^{-5\lambda}} = 1 - e^{-7\lambda}$$

O directamente por la propiedad de falta de memoria de la exponencial:

$$P(X \leq 12 | X \geq 5) = P(X < 7) = 1 - e^{-7\lambda}$$

De la muestra dada obtenemos $\bar{X} = 24.46$. Luego:

$$\hat{\lambda}^{MV} = \frac{1}{\bar{X}} = \frac{1}{24.46}$$

Utilizamos la propiedad de invarianza característica de los estimadores de máxima verosimilitud.

$$P(X \leq \widehat{12 | X} \geq 5) = 1 - e^{-7\hat{\lambda}^{MV}} = 1 - e^{-7 \cdot \frac{1}{24.46}} = 1 - e^{-\frac{7}{24.46}} \approx 0.249$$

Se estima que, aproximadamente, el 24,9% de las baterías se agotarán es decir 249 de las 1000 unidades.

Problema 5

Enunciado

Sea $X_1, \dots, X_n$ una muestra aleatoria simple de una distribución uniforme en $[-\theta, \theta]$ con $\theta > 0$.

¿Cuál el estimador de máxima verosimilitud del parámetro θ?

Resolución

$$f(x) = \begin{cases} \frac{1}{2\theta}, & -\theta \leq x \leq \theta \\ 0, & cc \end{cases}$$

$$L(x_1, \dots, x_n, \theta) = \begin{cases} \frac{1}{2\theta} \cdot \frac{1}{2\theta} \cdot \dots \cdot \frac{1}{2\theta} & si -\theta < x_i < \theta \ \ para\ todo\ x_i \\ 0 \ \ c.c. \end{cases}$$

$$= \begin{cases} \frac{1}{2^n \cdot \theta^n} & si \ \ |x_i| < \theta \ \ para\ todo\ x_i \\ 0 \ \ c.c. \end{cases} = \begin{cases} \frac{1}{2^n \cdot \theta^n} & si \ \ max\ |x_i| < \theta \\ 0 \ \ c.c. \end{cases}$$

Notar que $L(x_1, \dots, x_n, \theta)$ es una función NO DERIVABLE porque es discontinua. (Mirar el apunte donde hay un ejemplo similar con una $U(0, \theta)$.
Por lo tanto

$$\boxed{\hat{\theta} = max(|X_1|, \dots, |X_n|)}$$

Problema 7

Enunciado

Sea X_1, X_2, X_3 una muestra aleatoria simple de una población normal con media μ y varianza $\sigma^2 = 25$. Si $\hat{\mu}_1$ y $\hat{\mu}_2$ son los estimadores μ definidos por:

$$\hat{\mu}_1 = \frac{1}{4}(X_1 + 2X_2 + X_3)$$

$$\hat{\mu}_2 = \frac{1}{2}(X_1 + 2X_2 + X_3)$$

Se hacen una serie de afirmaciones acerca de las cuales la verdadera es que $\hat{\mu}_1$ es preferible antes $\hat{\mu}_2$, en la resolución demostraremos por qué.

Resolución

Comencemos por calcular el error cuadrático medio para $\hat{\mu}_1$:

$$E(\hat{\mu}_1) = E\left(\frac{1}{4}(X_1 + 2X_2 + X_3)\right) = \frac{1}{4}E(X_1 + 2X_2 + X_3) = \frac{1}{4} \cdot \big(E(X_1) + 2E(X_2) + E(X_3)\big) =$$

$$= \frac{1}{4} \cdot (\mu + 2\mu + \mu) = \frac{1}{4} \cdot 4\mu = \mu$$

Se utilizó la propiedad de linealidad del operador esperanza.

$$sesgo(\hat{\mu}_1) = E(\hat{\mu}_1) - \mu = \mu - \mu = 0$$

$$V(\hat{\mu}_1) = V\left(\frac{1}{4}(X_1 + 2X_2 + X_3)\right) = \left(\frac{1}{4}\right)^2 V(X_1 + 2X_2 + X_3) = \frac{1}{16}\big(V(X_1) + 2^2 V(X_2) + V(X_3)\big)$$

$$V(\hat{\mu}_1) = \frac{1}{16} \cdot 6 \cdot \sigma^2 = \frac{6}{16}\sigma^2$$

Se utilizaron las propiedades de la varianza y el hecho de que, dado que son pertenecen a una muestra aleatoria, X_1, X_2, X_3 son independientes.

$$ECM(\hat{\mu}_1) = \big(sesgo(\hat{\mu}_1)\big)^2 + V(\hat{\mu}_1) = 0^2 + \frac{6}{16}\sigma^2 = \frac{6}{16}\sigma^2 \rightarrow \boxed{ECM(\hat{\mu}_1) = \frac{3}{8}\sigma^2}$$

Calculemos, ahora, el error cuadrático medio para $\hat{\mu}_2$:

$$E(\hat{\mu}_2) = E\left(\frac{1}{2}(X_1 + 2X_2 + X_3)\right) = \frac{1}{2}E(X_1 + 2X_2 + X_3) = \frac{1}{2} \cdot \big(E(X_1) + 2E(X_2) + E(X_3)\big) =$$

$$= \frac{1}{2} \cdot (\mu + 2\mu + \mu) = \frac{1}{2} \cdot 2\mu = 2\mu$$

$$V(\hat{\mu}_2) = V\left(\frac{1}{2}(X_1 + 2X_2 + X_3)\right) = \left(\frac{1}{2}\right)^2 V(X_1 + 2X_2 + X_3) = \frac{1}{4}\big(V(X_1) + 2^2 V(X_2) + V(X_3)\big)$$

$$V(\hat{\mu}_2) = \frac{1}{4} \cdot 6 \cdot \sigma^2 = \frac{6}{4}\sigma^2$$

$$ECM(\hat{\mu}_2) = \big(sesgo(\hat{\mu}_2)\big)^2 + V(\hat{\mu}_2) = \mu^2 + \frac{6}{4}\sigma^2 \rightarrow \boxed{ECM(\hat{\mu}_2) = \mu^2 + \frac{3}{2}\sigma^2}$$

$$ECM(\hat{\mu}_1) = \frac{3}{8}\sigma^2 < ECM(\hat{\mu}_2) = \mu^2 + \frac{3}{2}\sigma^2 \rightarrow \boxed{\hat{\mu}_1 \text{ es mejor estimador que } \hat{\mu}_2}$$

Problema 8

Enunciado

Se quiere estudiar la relación entre la rentabilidad del trigo respecto del nivel de nitrógeno (N). Para ello, se plantó trigo en 7 parcelas de tierra de idénticas características y se les suministraron diferentes niveles de nitrógeno. Los resultados son los siguientes:

x Nivel de N	40	60	80	100	120	140	160
y Rentabilidad	15.9	18.8	21.6	25.2	28.7	30.4	30.7

¿Cuál es el intervalo de predicción de 95% para la rentabilidad del trigo cuando el nivel de nitrógeno en una nueva parcela es de 60 unidades?

<u>Resolución</u>

n	7
Σx_i	700
$\bar{x}$	100
$\Sigma {x_i}^2$	81200
Σy_i	171.3
$\bar{y}$	24.47143
$\Sigma {y_i}^2$	4398.19
$\Sigma x_i y_i$	18624
S_{xx}	11200
S_{yy}	206.23429
S_{xy}	1494

$$\hat{\beta}_1 = \frac{S_{xy}}{S_{xx}} = \frac{1494}{11200} = 0.13339$$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} = 24.47143 - 0.13339 \cdot 100 = 11.13214$$

$$\hat{y} = 0.13339 \cdot x + 11.13214$$

$$\hat{\sigma}^2 = \frac{S_{yy} - \frac{{S_{xy}}^2}{S_{xx}}}{n-2} = \frac{206.23429 - \frac{1494^2}{11200}}{5} = 1.38907$$

$$\hat{y}_0 = 0.13334 \cdot 60 + 11.13214 = 19.13254$$

$$1 - \alpha = 0.95 \rightarrow \alpha = 0.05 \rightarrow \frac{\alpha}{2} = 0.025$$

El intervalo de predicción de nivel 95% pedido será de la forma:

$$\left(\hat{y}_0 - t_{0.025,\,5} \sqrt{\hat{\sigma}^2 \left[1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}} \right]}, \hat{y}_0 + t_{0.025,\,5} \sqrt{\hat{\sigma}^2 \left[1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}} \right]} \right)$$

$t_{0.025,\,5} = 2.57058$

$$\sqrt{\hat{\sigma}^2\left[1+\frac{1}{n}+\frac{(x_0-\bar{x})^2}{S_{xx}}\right]} = \sqrt{1.38907\cdot\left[1+\frac{1}{7}+\frac{(60-100)^2}{11200}\right]} = 1.33639$$

La mitad de la longitud del intervalo buscado será entonces: $2.57058 \cdot 1.33639 = 3.43530$

$(19.13254 - 3.43530, 19.13254 - 3.43530) \approx \boxed{(15.7, 22.57)}$

Problema 9

Enunciado

Al fin de analizar el tiempo diario que los alumnos de la Facultad se conectan a las plataformas de enseñanza virtual los días sábado, se toma una muestra aleatoria simple $X_1, \dots, X_{100}$ midiendo los tiempos de conexión un día sábado determinado. A partir de ella se construye un intervalo de confianza para la media poblacional del nivel 95% que da (3.60, 4.20). ¿Cuál es el intervalo de confianza de nivel 99%?

Resolución

No sabemos a qué distribución responde la población, pero dado que $n = 100 \geq 30$ se puedo construir un intervalo de confianza de nivel aproximado 95%. El mismo responde a la forma:

$$\left(\bar{X} - z_{0.005}\frac{S}{\sqrt{n}}, \bar{X} - z_{0.005}\frac{S}{\sqrt{n}}\right) = \left(\bar{X} - 2.58\cdot\frac{S}{\sqrt{n}}, \bar{X} - 2.58\cdot\frac{S}{\sqrt{n}}\right)$$

Notar que $4.20 - 3.60 = 2\, z_{0.025}\, \frac{S}{\sqrt{n}} \;\rightarrow\; \frac{S}{\sqrt{n}} = \frac{4.20-3.60}{2\, z_{0.025}} = \frac{4.20-3.60}{2\times 1.96} = 0.15$

Entonces si ahora el intervalo debe ser del 99% su longitud es consecuentemente:

$$2.58\cdot\frac{S}{\sqrt{n}} = 2.58\cdot 0.15 = 0.39$$

Y, además, sabemos que $\bar{X}$ es el centro del intervalo (3.60, 4.20), es decir:

$$\bar{X} = \frac{3.60+4.20}{2} = 3.9$$

Finalmente, el intervalo de confianza del 99% para la media poblacional es:

$(3.9 - 0.39, 3.9 + 0.39) = \boxed{(3.51, 4.29)}$

Problema 10

Enunciado

Se extrae una muestra aleatoria de tamaño n de una variable aleatoria con función de densidad de probabilidad:

$$f(x) = \begin{cases} \dfrac{1+\theta x}{2}, -1 < x < 1 \\ 0, \quad caso\ contrario \end{cases}$$

Encontrar el estimador θ por el método de los momentos.

Resolución

El primer momento poblacional será:

$$E(x) = \int_{-1}^{1} x \cdot \frac{1+\theta x}{2} dx = \frac{\theta}{3}$$

El primer momento muestral es $\bar{X}$

Igualando los primeros momentos poblacionales y muestrales tenemos:

$$\frac{\theta}{3} = \bar{X} \rightarrow \theta = 3\bar{X}$$

$$\boxed{\hat{\theta}^{MM} = 3\bar{X}}$$